

# Maskco:掩码生成驱动有效的表示学习和组合优化开发

陈绿达, 李杨<sup>121</sup>, 闫俊驰<sup>12</sup>

<sup>1</sup>上海交通大学人工智能学院、计算机科学学院及致远学院

<sup>2</sup>上海创新研究院

{陈绿达, 杨丽丽, 延俊池}esjtu.edu.cn <https://github.com/Thinklab-SJTU/Maskco>

## 摘要

神经组合优化(NCO)长期以来一直锚定在解决方案构建或改进等范例中, 这些范例将解决方案视为整体参考, 浪费了嵌入在高质量解决方案中的丰富的局部决策模式。受语言和视觉中自我监督预训练的可扩展性的启发, 我们提出了一种观点的转变:组合优化是否可以采用一种基本的训练范式来实现可扩展的表示学习?我们介绍了MaskCO, 这是一种掩码生成方法, 它将学习重新定义为在给定参考解上的自监督学习。通过战略性地屏蔽部分最优解决方案和训练模型来恢复缺失的内容, MaskCO将单个实例解决方案对转化为大量局部学习信号, 迫使模型内化细粒度的结构依赖关系。在推理时, 我们采用了一个掩码和重构过程, 即迭代地掩码变量并重新生成它们以逐步提高解决方案质量的改进循环。我们的研究表明, 这些学习到的表征具有高度可转移性, 促进了有效的鳍调整, 并提高了替代推理方法的性能。实验结果表明, 与以前最先进的神经解算器相比, MaskCo取得了显著的性能改进, 将最优性差距缩小了99%以上, 并在旅行推销员问题(TSP)等问题上实现了10倍的加速。

## 1 简介

组合优化(CO)在复杂约束下的离散空间中寻求最优解, 支撑了许多关键应用(Korte等人, 2011;Wu et al, 2024b;Yang等人, 2024)。这些问题通常是NP-hard, 由于其固有的计算难度, 构成了重大挑战。传统方法依赖于手工制作的启发式, 难以平衡解决方案质量和计算效率(Helsgaun, 2017;Vidal et al., 2012)。最近, 神经组合优化(NCO) (Bengio等, 2021; Cappart et al, 2021), 已经成为一种变革性的替代方案, 利用深度学习以数据驱动的方式自动化启发式设计。与传统的启发式方法不同, NCO方法利用问题实例的结构化分布直接从数据中提取模式, 或通过定制算法从客观反馈中学习, 减少对人工干预的依赖, 同时实现具有竞争力或更高的解决方案质量和计算效率(Kool等人, 2018;孙与Yang, 203;Li等, 2004)。

许多CO任务可以转换为图上的变量决策问题, 其中模型试图确定构成高质量解决方案的一组目标变量。最近的进展通常通过将离散变量放松到连续空间并集成目标驱动策略来解决这些问题。这方面的主要方法包括无监督学习(Sanokowski等人, 24);

通讯作者。表示同等贡献。本工作得到国家自然科学基金(92370201,625B2119)和教育部基础与跨学科突破计划(JYB2025XDXM411)的部分支持。




图1:训练过程概述, 其中MaskCO屏蔽了部分最优解决方案, 并学习恢复丢失的内容。掩蔽比 $p$ 从 $[0,1]$ 均匀采样。

基于目标的微调(Sanokowski等人, 2023)和推理时间引导(Li等人, 2023c;2024;2025a), 很大程度上基于扩散模型(Ho et al, 2020;Sun & Yang, 2023)或基于树的搜索算法(Fu et al., 2021)。这些方法擅长于优化具有相对直接约束的问题的软约束形式, 例如图上的一般节点决策问题, 如最大独立集(MIS)和边缘决策问题, 如旅行推销员问题(TSP)。然而, 它们经常在更复杂的、硬约束的场景下挣扎, 比如有能力车辆路线问题(CVRP)。特别是对于vrp, 方法诉诸于顺序决策过程, 在每一步都强制执行约束, 或者通过自回归构建(Kool等人, 2018;Kwon et al., 2020; Kim et al., 2022;Luo等人, 2024;Zhou等人, 2024a)或通过马尔可夫决策过程(MDP)中制定并使用强化学习(RL)训练的局部搜索动作(da Costa等人, 2020;Sui等人, 2021;Ma等, 2021;2023)。

随着基于学习的CO的发展, 模型和训练的复杂性已经同步增长, 越来越依赖于特定问题的设计。从根本上说, 大多数现有方法仍然锚定在将解决方案视为整体对象的构建或改进范式中。这种实例级的关注使得高质量解决方案中固有的丰富的本地化决策模式在很大程度上没有得到探索, 从而导致数据利用效率低下和可扩展性有限。这种限制在Co中尤其重要, 因为在Co中获得可靠的监控信号通常是昂贵的。这种低效率反映了自然语言处理和计算机视觉领域的历史挑战, 这些领域的进步一度受到严重依赖特定任务标签的限制。该领域由自我监督预训练(Liu et al., 2021)彻底改变, 由GPT中的下一个令牌预测等范式驱动(Radford et al., 2018;Brown等人, 2020)和BERT和MAE中的掩码自动编码(Devlin等人, 2019;He et al., 2022)。通过使模型能够更深入地挖掘原始数据, 这些方法解锁了大规模捕获潜在模式的能力, 以最小的任务特定工程实现了前所未有的泛化。这些成功为CO提出了一个核心问题:我们是否可以采用类似的基础训练范式来实现有效和可扩展的表示学习?

在本文中, 我们提出了一个掩码生成范式, 该范式将学习重新定义为对给定参考解决方案的自监督学习。我们的关键见解是, 最优解非常像句子或图像, 编码分层决策模式和反复出现的局部子结构(例如:例如, 路由中的高效子路线, 图问题中的连贯节点簇)。通过战略性地屏蔽这些解决方案的部分内容和训练模型来重建缺失的内容, MaskCO迫使模型内部化细粒度、本地化的决策逻辑。这种方法成倍地增加了数据效用, 将单个(实例, 解决方案)对转换为(实例, 部分解决方案)训练示例的多样化课程, 如图图所示。

在推理时, 我们采用多步并行解码, 自然地利用了训练目标:在每一步, 模型同时预测所有变量, 并有选择地提交置信度最高的组件, 重复直到解决方案完成。此外, 我们引入了一个掩码和重构过程, 以实现类似局部搜索的细化。通过在候选解的屏蔽段之间交替并重建它们, 该模型在几次迭代中逐步提高了解的质量。灵活的掩蔽机制提供了对约束满意度的细粒度控制, 弥合了有效的基于hetmap的推断和复杂约束处理之间的差距。我们还发现, 学习到的表征可以有效地转移到不同的推理线, 并支持具有替代融合形式的有效映射。

我们的贡献有三个方面:(1)我们提出蒙面生成作为NCO的一种新的基础范式, 将求解转化为解决方案级的自我监督过程。通过训练模型来恢复最优解决方案的策略掩蔽组件, 该框架强制学习嵌入在解决方案结构中的细粒度局部决策模式, 在保持简单性的同时实现强大的表示学习。(2)为了充分利用学习到的表示, 我们设计了一种直接推理算法, 通过迭代掩模和再生来动态激活模型知识, 模拟了计算效率高的搜索行为。(3)大量的实验证明了MaskCO在TSP、CVRP和MIS上的最先进性能。

## 2 相关作品

神经组合优化。基于学习的组合优化(CO)求解器通常利用神经网络来构建解决方案或增强现有解决方案, 目的是直接最小化目标分数(Bengio et al., 2021)。这通常通过强化学习来实现(Kool et al., 2018;Kwon等人, 2020;Kim等, 2022;邱等, 2022;Min等人, 2024)或通过使用监督学习将预测与参考解决方案对齐(Vinyals等人, 2015;Joshi等人, 2019;Hudson等人, 2022;Fu等人, 2021;Luo et al., 2024)。ML4TSPBench (Li et al., 2025c)和ML4CO-Bench-101 (Ma et al., 2025b)为特定路由问题和一般CO域的现有方法提供了系统的概述和实现基础。

基于构造的方法可以分为自回归方法和非自回归方法。自回归方法(Khalil et al, 2017;Kool et al, 2018;Kwon等人, 2020;Hottung等, 2021;Kim等人, 2022)顺序确定决策变量, 直到构建完整的解决方案, 而非自回归方法(Joshi等人, 2019;Fu et al., 2021;Geisler等, 2022;邱等人, 2022;郑等, 2024;Wang et al., 2023)一步预测软约束解, 然后进行后处理以确保可行性。近年来, 生成模型(Sun & Yang, 2023;Guo et al., 2024;Chen等, 2024;Ma等, 2025a;Wang等;Li等人, 2023c;b;2024;2025a;d)由于其强大的表征能力和建模信息分布的能力, 在CO中显示出前景, 这是一种具有更高模型表达能力的非自回归方法。尽管取得了成功, 但这些方法通常在单块实例解决方案级别上运行, 仅在最终输出上执行目标。这忽略了最优解决方案中固有的颗粒化、本地化决策模式。相反, 基于改进的求解器(d O Costa等人, 2020;Wu et al., 2021;陈田等, 2019;Li等, 2021;侯等人, 2023;Wang等人, 2025a)专注于通过神经网络引导的局部搜索来提炼解决方案。虽然这允许在优化过程中进行反馈, 但缺乏全局指导通常会降低这种反馈的可靠性。此外, 问题分解策略(Luo et al., 2024;Drakulic等人, 2023;Ye et al, 2024)探索了将大问题分解为更小的子问题, 这些子问题可以局部解决, 然后集成以实现全局解决方案。虽然这些策略捕获了局部解决方案模式, 但它们通常需要针对特定问题量身定制的特定管道设计。

最近, 受CV和NLP中多任务学习成功的启发, 人们开始研究CO中的多任务学习(Drakulic等人, 2025;Zhou et al., 2024b;Berto等, 2025;Pan等人, 2025;Zong等人, 2025)。虽然最近的一些工作将自我监督引入了NCO (Zong等人, 2025), 但MaskCO走的是一条独特的道路。而不是仅仅专注于跨问题泛化, 我们利用自监督掩码生成来最大化特定问题的表征能力。通过内部化本地化的结构依赖, MaskCO在解决方案质量上达到了一个新的水平, 为未来的多任务扩展提供了一个更鲁棒的架构基础。

预训练和蒙面生成。自监督学习技术, 包括对损坏输入或缺失信息的预训练, 因其在没有标记数据的情况下学习有用表示的能力而获得了相当大的关注, 从而促进了基础模型的发展(Li等人, 2025b;Long et al, 2026;In等, 2025;刘等, 25;;206;王等a, 25b)。掩码生成(自动编码)首先由BERT (Devlin等人, 2019)引入, 用于自然语言理解, 是自监督预训练中的一个关键概念。这种方法包括屏蔽部分输入和训练模型来预测缺失的内容, 这种方法已被证明在各个领域都非常有效。在视觉表示学习的背景下, 这个想法通过使用离散标记器得到了扩展(Bao等人, 2022;He et al, 2021), 展示了其有效处理非顺序结构化数据的能力。最近的作品(Chang et al., 2022;Li等人, 203a)进一步证明了掩码生成可以有效地进行图像合成

使用非自回归解码的固定步数，展示了其卓越的可扩展性和更广泛应用的潜力，特别是在CO领域，其中问题以离散决策空间为特征，表现出非顺序性质，并且需要高度可扩展的方法。

### 3 初步和记号

图的组合优化。遵循标准实践Karalias & Loukas (2020);Wang等人(2022)，我们考虑一组图实例 $g$ 。每个实例都是一个图 $g = (V, E)$ ，具有顶点集 $V$ 和边集 $E$ 。许多CO任务可以被定义为选择一个地面集 $U(g)$ 的子集:边决策问题(例如，TSP)选择边，因此 $U(g) = E$ ;节点决策问题(例如MIS)选择顶点，因此 $U(G) = V$ 。

我们用一个二元指标 $x \in \{0,1\}^{U(G)}$ 表示选择，其中 $x_u = 1$ 表示 $U(G)$ 被选中。可行集 $\mathcal{C}(G) \subseteq \{0,1\}^{U(G)}$ 包含满足问题约束的选择。目标是找到最小化给定目标 $l(g;G)$ 的可行选择:  $\{0,1\}^{U(G)}$  - R20:

$$\min_{x \in \mathcal{C}(G)} l(x; G). \quad (1)$$

约束可以作为硬可行性(编码在 $\mathcal{C}(G)$ 中)或作为软惩罚(编码在 $l(x;G)$ 中)强制执行，具体取决于问题。选择问题可以定义如下。

定义3.1(选择问题)。一个二进制向量 $x \in \{0,1\}^{U(G)}$ 是一个部分解，对于 $G$ 存在一个可行解 $x' \in \mathcal{C}(G)$ 使得 $x < x'$  (elementwise)。我们用 $S(G)$ 表示所有偏解的集合。

直观地说，偏解选择至少与一个可行的完全解一致的变量子集。

定义3.2(选择函数)。给定一个实例 $G$ ，选择运算符是一个函数

$$f_G : \hat{\Omega}(G) \times [0, 1]^{|U(G)|} \times \mathbb{N} \rightarrow \hat{\Omega}(G) \quad (2)$$

给定一个偏解 $x$ ，选择分数 $p$ ，目标大小 $k$ ，返回一个满足以下条件的扩展偏解:

单调性:  $x \leq f(x, p, k)$ ,

- 目标大小或极大性: 要么 $f(x, p, k) \geq k$ ，要么没有元素可以添加而不违反可扩展性(即结果是最大化 $f(G)$ )。

一个典型的实例是贪婪算子:对 $u \in U(G)$ 按 $P_u$ 排序，在部分解保持可扩展性的情况下，逐个向 $x$ 添加元素;当达到目标大小 $k$ 或不存在进一步的有效加法时停止。对于固定的解决方案大小，将 $k$ 设置为该大小会产生一个完整的解决方案。

示例。TSP定义在一个完全无向图上，其中顶点是城市，边带有非负权(例如，距离)。该解决方案选择形成哈密顿循环的精确 $V$ 个顶点，并最小化行程长度。MIS在无向图 $G = (V, E)$ 上定义;解选择无相邻对的顶点的最大基数子集。对于CVRP这样的路由问题，根据求解器的设计，容量约束可以在 $\mathcal{C}(G)$ 中被视为硬可行性，也可以在 $l(x)$ 中被放松并作为惩罚嵌入。

## 4 方法学

我们提出了一个基于掩模生成的组合优化的通用和原则性范例，该框架既灵活，适应不同的问题公式，又对特定问题组件的依赖最小。

### 4.1 解决方案级的训练自监督学习

从蒙面自编码器在语言和视觉预训练中的成功中获得灵感(He et al, 2022)，其中模型通过重构路线输入来学习robust表示

一个类似的CO基本范例，支持在最优解决方案中对决策模式进行可扩展、高效的学习。在CO中，最优解固有地编码重复的局部子结构。通过将这些解视为子结构的复合图，我们设计了一个训练任务，该任务要求模型根据部分上下文推断缺失的组件。这种方法利用了CO解决方案的组合特性，鼓励模型学习可重用的决策模式，而不是记忆单一的解决方案。

具体来说，给定一个完整的最优解 $x^* \in U(G)$ ，我们通过从 $x$ 中采样元素的子集来构造一个部分解 $f(G)$ 。这个子集采样由分布 $D$ 控制，在 $(0,1)$ 区间内，它控制保留元素的比例。在每次训练迭代中，我们首先采样一个比率 $t \sim D$ ，然后从 $X$ 中均匀地保留 $\lceil t \cdot |X| \rceil$ 个元素来形成部分解 $X$ 。默认情况下，我们对 $D$ 使用均匀分布，这是一种简单的策略，每次都掩盖相同数量的变量。从单个解 $x^*$ 开始，采样过程生成指数级多的偏解，显著提高了数据效率。

设 $p_\theta(G, X) \in [0,1]^{U(G)}$ 表示模型在实例 $G$ 和偏解 $X$ 条件下的预测选择概率。以真实值指标 $x^*$ 为目标，我们将训练损失定义为变量二元交叉熵：

$$\mathcal{L}(\theta; G, \hat{x}, x^*) = \text{BCE}(p_\theta(G, \hat{x}), x^*) = - \sum_{u \in U(G)} [x_u^* \log p_{\theta,u} + (1 - x_u^*) \log(1 - p_{\theta,u})]. \quad (3)$$

该公式将每个掩蔽位置视为一个独立的二元分类任务，其中模型根据当前上下文学习预测变量是否属于最优解。重要的是，通过在训练过程中迭代地掩盖解决方案的不同子集，模型暴露于不同的推理路径，并学习一个在不同部分状态上泛化良好的上下文置信估计器。

#### 4.2 用于掩蔽生成的多步解码

我们的多步解码框架通过动态平衡探索和利用的迭代细化过程逐步构建解决方案。该方法利用一个调度函数 $[0,1] \rightarrow [0,1]$ 来控制解的增长率，解的增长率单调递增，且 $(0)=0$ ， $(1)=1$ 。这个函数协调了从广泛探索潜在的解组件到精确开发最有希望的元素的逐渐过渡。在实践中，我们采用线性实现 $t = t$ ，这在整个过程中提供了统一的增长。

对于所有可行解共享固定基数 $m$ 的CO问题(例如具有 $m$ 条边的TSP旅行)，解码过程通过 $K$ 个确定性步骤的预定序列进行。从一个空的偏解 $x(0) = 0$ 开始，在每一步 $i \in [K]$ 中，我们采用贪心选择函数，通过根据模型的输出热图 $p_\theta(G, (-1) \in [0,1]^{U(G)})$ ，在尚未包含的候选变量中选择具有最高预测置信度的候选变量来扩展解。对于选择函数 $f$ ，增量构造得到了很好的治理，即在每一步中所选元素的总数达到 $\lceil (i/K) \cdot m \rceil$ 。形式上，我们有：

$$\hat{x}^{(i)} \leftarrow f_G(\hat{x}^{(i-1)}, p_\theta(G, \hat{x}^{(i-1)}), \lceil \gamma(i/K) \cdot m \rceil), \quad i \in [K]. \quad (4)$$

通过构造，最终的部分解满足 $(K)=m$ ，是可行的。

当处理具有可变解决方案基数的问题(如MIS)时，首先通过对模型的预测求和来获得解决方案大小的估计 $m_\theta(X)$ ：

$$m_\theta(G, \hat{x}) := \sum_{u \in U(G)} p_{\theta,u}(G, \hat{x}). \quad (5)$$

在此估计的基础上，相应地，迭代处理过程变为

$$\hat{x}^{(i)} \leftarrow f_G(\hat{x}^{(i-1)}, p_\theta(G, \hat{x}^{(i-1)}), \lceil \gamma(i/K) \cdot m_\theta(G, \hat{x}^{(i-1)}) \rceil), \quad i \in [K]. \quad (6)$$

由于最后的迭代可能是不可行的，如果 $(K)$ 我们应用一个补全步骤：

$$\hat{x} \leftarrow f_G(\hat{x}^{(K)}, p_\theta(G, \hat{x}^{(K-1)}), |U(G)|), \quad (7)$$

重用之前的分数，避免重新计算，保持一致性。附录B.4中讨论了替代完成策略。




图2:迭代推理过程概述。通过基于神经预测的重复掩蔽和重建部分解决方案，逐步完善解决方案。

### 4.3 高级校正框架:掩模和重构

确定性解码过程虽然有效，但一旦形成初始解决方案，就会固有地限制探索，因为它顺序地承诺不可逆转的决策，这可能会将构造困在次优配置中。为此，我们引入了一种能够实现迭代解修正的掩码和重构机制。具体来说，在每次迭代中，根据预定义的保持率 $p$ ，这些元素的子集被随机屏蔽，从而得到部分解 $x$ 。在重建过程中，模型通过一个由平移调度函数 $p(r) = p + (1 - p) \cdot (r)$ 控制的自适应多步解码过程重新生成被屏蔽的区域，它调整解码轨迹，专注于重建解中缺失的 $1 - p$ 部分。

通过将重建的早期步骤锚定到 $X$ 中保留的元素，该模型利用未屏蔽部分作为上下文锚点，同时概率地探索被屏蔽区域的替代配置。移位的调度 $\gamma_p$ 确保解码过程从部分解现有的完备性水平 $p$ 开始，并在 $K$ 步内逐步向完全重构方向发展。至关重要，掩蔽率 $p$ 控制着探索和开发之间的权衡:较低的 $p$ 值导致更大的解段的积极重新优化，而较高的 $p$ 值则实现更局部、更细粒度的改进。

完整的求解流程如图图1所示，包括构建和修正两个阶段。在构建阶段，

#### Algorithm 1 Inference Algorithm

```

1: Input: multi-step decoding function  $\text{Decode}_{f_G, \theta, K}(\cdot)$  with respect to instance  $G$ ,
   model parameters  $\theta$ , selection operator  $f_G$ , and
   number of iterations per decode  $K$ ; schedules  $\gamma(\cdot)$ 
   and  $\gamma_p(\cdot)$ ; total budget  $T$ ; masking rate  $p \in [0, 1]$ ;
   objective  $l(\cdot; G)$ 
2:  $\mathbf{x} \leftarrow \text{Decode}_{\theta, f_G, K}(\mathbf{0}, \gamma)$ 
3:  $\mathbf{x}_{\text{best}} \leftarrow \mathbf{x}$ 
4: for  $i = 1$  to  $\lfloor T/K \rfloor - 1$  do
5:    $\hat{\mathbf{x}} \leftarrow \text{RandomlyMask}(\mathbf{x}, p)$ 
6:    $\mathbf{x} \leftarrow \text{Decode}_{\theta, f_G, K}(\hat{\mathbf{x}}, \gamma_p)$ 
7:   if  $l(\mathbf{x}; G) < l(\mathbf{x}_{\text{best}}; G)$  then
8:      $\mathbf{x}_{\text{best}} \leftarrow \mathbf{x}$ 
9:   end if
10: end for
11: return  $\mathbf{x}_{\text{best}}$ 

```

使用基本解码方法从零开始生成初始解。随后是多轮校正阶段，其中掩码和重构机制迭代地改进解决方案，逐步提高其质量。这种方法将静态解生成转化为动态的、内存增强的搜索过程。先前确定的高质量子结构可以作为后续改进的指南，而屏蔽的受控应用保留了探索解决方案空间新区域的灵活性。因此，用掩模损失训练的模型作为有效的组合模型表现出强大的性能，证明了将表示学习转化为实际问题解决能力的有效性。

### 4.4 模型。architecture

我们采用了一种编码器-解码器Transformer架构(Vaswani, 2017)，选择它是因为它能够通过自注意力机制机制对组合结构中的复杂依赖关系进行建模。节点特征被线性投影到嵌入空间中。由0-1邻接矩阵表示的边缘连接通过加性偏差被纳入注意机制。形式上，

表1:不同尺寸的TSP结果。

| METHOD                                                            | TSP-100 |         |        | TSP-500 |         |         | TSP-1000 |         |        |
|-------------------------------------------------------------------|---------|---------|--------|---------|---------|---------|----------|---------|--------|
|                                                                   | OBJ.    | GAP     | TIME   | OBJ.    | GAP     | TIME    | OBJ.     | GAP     | TIME   |
| Concorde (Applegate et al., 2006)                                 | 7.756   | 0.00%   | 12m*   | 16.55   | 0.00%   | 37.66m* | 23.12    | 0.00%   | 6.65h* |
| LKH-3 (Helsgaun, 2017)                                            | 7.756   | 0.00%   | 33m*   | 16.55   | 0.00%   | 46.28m* | 23.12    | 0.00%   | 2.57h* |
| BQ-NCO (bs16) (Drakulic et al., 2023)                             | 7.757   | 0.016%  | 1m41s  | 16.637  | 0.551%  | 5m50s   | 23.436   | 1.374%  | 14m30s |
| LEHD (RRC 1000) (Luo et al., 2024)                                | 7.756   | 0.0019% | 7.87m  | 16.575  | 0.175%  | 37.54m  | 23.286   | 0.726%  | 3.35h  |
| SIT (RRC 1000) (Luo et al., 2025)                                 | -       | -       | -      | -       | -       | -       | 23.206   | 0.381%  | 1.59h  |
| Poppy (16) (Grinsztajn et al., 2023)                              | 7.770*  | 0.07%*  | 1m*    | -       | -       | -       | -        | -       | -      |
| PolyNet (sampling) (Hottung et al., 2025)                         | 7.756   | 0.0006% | 0.36m  | -       | -       | -       | -        | -       | -      |
| PolyNet (EAS) (Hottung et al., 2025)                              | 7.756   | 0.0000% | 20.66m | -       | -       | -       | -        | -       | -      |
| DIFUSCO (T <sub>r</sub> =100) (Sun & Yang, 2023)                  | 7.76    | 0.06%   | 30m    | 16.69   | 0.87%   | 19.1m   | 23.42    | 1.31%   | 51.9m  |
| Fast T2T (T <sub>r</sub> =5, T <sub>g</sub> =5) (Li et al., 2024) | 7.76    | 0.01%   | 8.3m   | 16.58   | 0.21%   | 6.9m    | 23.22    | 0.42%   | 18.3m  |
| MaskCO (T=320)                                                    | 7.756   | 0.0000% | 8s     | 16.546  | 0.0020% | 6s      | 23.120   | 0.0071% | 18s    |
| MaskCO (T=640)                                                    | 7.756   | 0.0000% | 15s    | 16.546  | 0.0014% | 12s     | 23.119   | 0.0051% | 33s    |
| MaskCO (T=1280)                                                   | 7.756   | 0.0000% | 30s    | 16.546  | 0.0012% | 23s     | 23.119   | 0.0038% | 1m6s   |
| MaskCO (T=2560)                                                   | 7.756   | 0.0000% | 1m0s   | 16.546  | 0.0007% | 43s     | 23.119   | 0.0027% | 2m8s   |

注意逻辑计算为 $Z = QTK + A$ ，其中 $q$ 和 $K$ 分别表示查询矩阵和键矩阵； $A$ 是编码节点间有无边的邻接矩阵，直接添加到 $QT$   $K$ 中，不做任何缩放； $Z$ 表示在应用softmax函数之前得到的注意力logits。对于节点选择问题，将节点特征投影到一维空间中获得logits。对于边选择问题，使用源节点和目标节点嵌入的点积来评估成对兼容性。

## 5 实验

问题设置。我们遵循标准的数据生成程序来生成TSP、CVRP和MIS数据集。对于TSP， $n$ 个节点位置在单位方中均匀随机采样(Kool等, 2018; Kwon et al., 2020; Li等, 2024; 周等, 2024a; Ma等, 2021; 2023)。对于CVRP，仓库位置以及 $n$ 个客户位置在单位正方形中均匀随机采样(Kool等人, 2018)。客户需求从 $\{(1, .), 9\}$ ，车辆容量 $D$ 在问题大小上设置为50。对于MIS，测试了两个数据集，包括RB图(Zhang et al., 2023)和ErdsRnyi (ER)图(Erdos et al., 1960)。对于RB图，我们均匀地随机抽取200到300个顶点并生成图实例。ER图是随机生成的，每条边保持一个固定的存在或不存在的概率，独立于其他边。我们采用700 ~ 800个节点的ER图，两两连接概率集为0.15。数据集配置见附录E.3。

求解设置:1)Forward Passes  $T$ ，即在每个实例求解过程中执行的模型Forward Passes总数。2)采样步数 $K$ ，参数化多步解码。3)保持率 $p$ ，即在每个校正步骤中保留的变量比例。因此，求解过程包括一个初始构建阶段，随后是 $T/K$  -1校正迭代。在每个表中报告 $T$ 的值作为计算预算，而 $K$ 和 $p$ 的详细配置在附录E.2中提供。对于vrp，在校正步骤之间应用带有惩罚项的2-opt启发式，以强制执行约束并提高解决方案质量。对于所有基线，除非另有明确说明，否则我们采用原始论文中报告的最佳超参数。标注\*的指标引用自(Li等人, 2024; Grinsztajn et al, 2023)。CVRP-1000上的SIT由我们重新培训，因为 $C = 50$ 的设置没有公开可用的检查点。所有其他基线都通过评估其提供的检查点来评估。

### 5.1 主要结果

TSP结果。表1给出了求解器在不同问题规模的TSP上的结果。经典求解器的性能取自Li et al.(2024)。像协和式和LKH-3这样的传统求解器在所有规模上实现了0.00%的差距，但它们的计算时间明显更长，特别是对于更大的问题规模。相比之下，DIFUSCO和Fast T2T等基于生成的方法显示出稍高的差距(TSP-100的差距为0.06%和0.01%)，但它们大大减少了计算时间，Fast T27只需8.3分钟即可完成TSP-10。不可思议的是，MakCO优于其他所有方法，在显著减少计算时间的同时，实现了所有尺寸的接近零差距。与之前最先进的神经解算器相比，MaskCO实现了显著的性能改进，在最优性差距缩小方面超过了9%，同时加速了10倍。

表2:不同尺寸的CVRP结果。

| METHOD                                    | CVRP-100 |        |        | CVRP-500 |        |        | CVRP-1000 |        |       |
|-------------------------------------------|----------|--------|--------|----------|--------|--------|-----------|--------|-------|
|                                           | Obj.     | GAP    | TIME   | Obj.     | GAP    | TIME   | Obj.      | GAP    | TIME  |
| HGS (Vidal et al., 2012)                  | 15.550   | 0.000% | 13h    | 62.15    | 0.000% | 55h    | 121.07    | 0.000% | 197h  |
| POMO (Kwon et al., 2020)                  | 15.750   | 1.287% | 8s     | —        | —      | —      | —         | —      | —     |
| ICAM (Zhou et al., 2024a)                 | 15.859   | 1.985% | 5s     | 63.28    | 1.813% | 28s    | 123.02    | 1.610% | 1m56s |
| UDC (Zheng et al., 2025)                  | —        | —      | —      | 65.43    | 5.278% | 5m56s  | 127.07    | 4.954% | 4m25s |
| BQ-NCO (bs16) (Drakulic et al., 2023)     | 15.794   | 1.572% | 2.74m  | 63.53    | 2.219% | 5.86m  | 123.56    | 2.059% | 7.73m |
| LEHD (RRC 1000) (Luo et al., 2024)        | 15.617   | 0.433% | 9.53m  | 62.94    | 1.275% | 38.27m | 123.33    | 1.859% | 1.83h |
| ReLD (augx8) (Huang et al., 2025)         | 15.785   | 1.509% | 0.12m  | 64.16    | 3.241% | 0.17m  | 125.06    | 3.297% | 0.34m |
| SIT (RRC 1000) (Luo et al., 2025)         | —        | —      | —      | —        | —      | —      | 126.55    | 4.528% | 1.23h |
| Poppy (32) (Grinsztajn et al., 2023)      | 15.73*   | 1.06%* | 5m*    | —        | —      | —      | —         | —      | —     |
| PolyNet (sampling) (Hottung et al., 2025) | 15.627   | 0.496% | 0.46m  | —        | —      | —      | —         | —      | —     |
| PolyNet (EAS) (Hottung et al., 2025)      | 15.571   | 0.139% | 25.40m | —        | —      | —      | —         | —      | —     |
| NeuOpt (D2A=5,T=40k) (Ma et al., 2023)    | 15.566   | 0.103% | 4h49m  | —        | —      | —      | —         | —      | —     |
| MaskCO (T=640)                            | 15.586   | 0.232% | 32s    | 62.66    | 0.813% | 21s    | 122.03    | 0.798% | 44s   |
| MaskCO (T=1280)                           | 15.577   | 0.176% | 1m3s   | 62.59    | 0.714% | 40s    | 121.85    | 0.644% | 1m7s  |
| MaskCO (T=2560)                           | 15.571   | 0.135% | 2m5s   | 62.53    | 0.608% | 1m18s  | 121.69    | 0.514% | 2m2s  |
| MaskCO (T=5120)                           | 15.567   | 0.111% | 4m9s   | 62.47    | 0.514% | 2m35s  | 121.63    | 0.460% | 3m51s |
| MaskCO (T=10240)                          | 15.563   | 0.086% | 8m17s  | 62.43    | 0.448% | 5m8s   | 121.60    | 0.438% | 7m33s |

表3:不同规模MIS的结果。

| METHOD                             | RB-[200-300] |        |        | ER-[700-800] |        |        |
|------------------------------------|--------------|--------|--------|--------------|--------|--------|
|                                    | Obj.         | GAP    | TIME   | Obj.         | GAP    | TIME   |
| KaMIS (Lamm et al., 2016)          | 20.10*       | —      | 1.4h   | 44.87*       | —      | 52.1m  |
| Gurobi (Gurobi Optimization, 2020) | 19.98        | 0.01%  | 47.6m  | 41.28        | 7.78%  | 50.0m  |
| Intel (Li et al., 2018)            | 18.47        | 8.11%  | 13.1m  | 38.80        | 13.43% | 20.0m  |
| DGL (Bother et al., 2022)          | 17.36        | 13.61% | 12.8m  | 37.26        | 16.96% | 22.7m  |
| GFlowNets (Zhang et al., 2023)     | 19.18        | 4.57%  | 32s    | 41.14        | 8.53%  | 2.9m   |
| DIFUSCO (Sun & Yang, 2023)         | 19.13        | 4.79%  | 20.5m  | 39.12        | 12.81% | 21.7m  |
| T2T (Li et al., 2023c)             | 19.38        | 3.53%  | 30.3m  | 41.41        | 7.72%  | 27.8m  |
| Fast T2T (Li et al., 2024)         | 19.49        | 2.89%  | 4.7m   | 40.68        | 9.34%  | 1.5m   |
| MaskCO (T=1k)                      | 20.00        | 0.49%  | 44s    | 43.20        | 3.73%  | 1m21s  |
| MaskCO (T=2k)                      | 20.03        | 0.37%  | 1m27s  | 43.59        | 2.84%  | 2m42s  |
| MaskCO (T=4k)                      | 20.06        | 0.21%  | 2m54s  | 43.86        | 2.23%  | 5m24s  |
| MaskCO (T=8k)                      | 20.07        | 0.15%  | 5m48s  | 44.12        | 1.68%  | 10m48s |
| MaskCO (T=16k)                     | 20.08        | 0.12%  | 11m36s | 44.38        | 1.09%  | 21m36s |
| MaskCO (T=32k)                     | 20.08        | 0.10%  | 23m12s | 44.59        | 0.62%  | 43m12s |

表4:TSPLIB的概化。

|                | ICAM  | Fast T2T | NeuOpt | MaskCO        |
|----------------|-------|----------|--------|---------------|
| TSPLIB50-200   | 2.38% | 0.28%    | 0.35%  | <b>0.033%</b> |
| TSPLIB201-1000 | 6.49% | 0.93%    | —      | <b>0.115%</b> |

表5:消融对校正机制的研究。

| CONFIG.               | TSP-500 |         |      |
|-----------------------|---------|---------|------|
|                       | Obj.    | GAP     | TIME |
| w/o corr. (T=K=1)     | 16.689  | 0.8656% | <1s  |
| w/o corr. (T=K=8)     | 16.563  | 0.1015% | <1s  |
| w/o corr. (T=K=64)    | 16.556  | 0.0606% | 1s   |
| w/o corr. (T=K=320)   | 16.554  | 0.0520% | 6s   |
| w/ corr. (T=320, K=1) | 16.546  | 0.0020% | 6s   |

表4给出了实际TSPLIB数据集上的泛化性能。我们在50-200个节点的TSPLIB实例上评估用100节点问题训练的模型，在200-1000个节点的TSPLIB实例上评估500节点模型，使用T = 25600。与之前的SOTAs相比，MaskCO在TSPLIB 50-200和TSPLIB 200-1000上分别实现了从0.28%到0.033%(88.2%的改善)和从0.93%到0.115%(87.6%的改善)的显著改善。

CVRP结果。表2突出了MaskCO的明显性能优势。对于CVRP-100, MaskCO (T=640)比构造解需要更多的时间(从8秒到325),但在溶液质量方面取得了实质性的改善(从1.287%到0.232%)。与NeuOpt (Ma et al., 2023)等基于搜索的基线相比，虽然它实现了大约0.1%的差距，但它需要更多的时间(4h49m)，而MaskCO可以在8m17s内实现0.086%，提供34.9倍的加速。在更大的实例中，许多基线变得不可行的。与SOTAs相比，MaskCO具有640次正向传递，在解决方案质量和求解速度方面已经优于以前的方法，实现了53%的平均性能增益和64%的加速。通过使用更多的计算，MaskCO在CVRP-500和cvrp - 1000上分别获得了0.448%和0.438%的显著最优性差距。此外，随着向前传球次数的增加，MaskCO也在不断改进。

MIS结果。表3显示，仅向前传递1000次的MaskCO已经优于以前最先进的方法，在RB数据集上4秒内实现0.4%的差距，在ER数据集上1.3分钟内实现37%的差距。与之前的方法相比，这使得最优性差距平均提高了72%，运行时加速了3倍。随着向前传递次数的增加，MaskCO继续提高解决方案的质量，不断缩小差距。通过32k的正向传递，MaskCO在RB和ER数据集上分别实现了0.0%和0.62%的差距，通过比最佳生成状态-at方法高出94%，设定了新的基准。

## 5.2 适应替代训练和解码方法

我们证明了用屏蔽信号建模训练的模型可以直接适应其他解码例程或通过少量样本学习微调。具体来说，我们使用自回归(AR)解码、双向AR解码、放松AR解码和微调来评估模型

表6:微调和备选解码的结果。S:样本数;T:采样步长。

| DECODING METHOD                                          | TSP-100 |         |      | TSP-500 |        |       | TSP-1000 |        |       |
|----------------------------------------------------------|---------|---------|------|---------|--------|-------|----------|--------|-------|
|                                                          | OBJ.    | GAP     | TIME | OBJ.    | GAP    | TIME  | OBJ.     | GAP    | TIME  |
| Direct Evaluation                                        |         |         |      |         |        |       |          |        |       |
| AR (aug×8)                                               | 7.756   | 0.0004% | 19s  | 16.549  | 0.018% | 1m42s | 23.136   | 0.078% | 10m4s |
| AR (2Opt, aug×8)                                         | 7.756   | 0.0004% | 19s  | 16.548  | 0.012% | 1m42s | 23.125   | 0.030% | 10m4s |
| Bidirectional AR (aug×8)                                 | 7.756   | 0.0007% | 19s  | 16.549  | 0.021% | 1m42s | 23.215   | 0.419% | 10m4s |
| Bidirectional AR (2Opt, aug×8)                           | 7.756   | 0.0006% | 19s  | 16.549  | 0.019% | 1m42s | 23.141   | 0.098% | 10m4s |
| Relaxed AR (aug×8)                                       | 7.756   | 0.0016% | 19s  | 16.549  | 0.019% | 1m41s | 23.128   | 0.043% | 10m4s |
| Relaxed AR (2Opt, aug×8)                                 | 7.756   | 0.0016% | 19s  | 16.548  | 0.014% | 1m41s | 23.125   | 0.028% | 10m4s |
| 1-Epoch Finetuning                                       |         |         |      |         |        |       |          |        |       |
| Consistency (S=8, T <sub>s</sub> =64) (Li et al., 2024)  | 7.756   | 0.0008% | 15s  | 16.552  | 0.040% | 29s   | 23.148   | 0.131% | 2m13s |
| Consistency (S=8, T <sub>s</sub> =256) (Li et al., 2024) | 7.756   | 0.0004% | 1m0s | 16.550  | 0.025% | 1m47s | 23.143   | 0.107% | 8m54s |

表7:建筑消融研究。

| T    | BACKBONE    | TSP-500        | TSP-1000       |
|------|-------------|----------------|----------------|
| 320  | Transformer | 0.0020%, 6s    | 0.0071%, 18s   |
|      | GCN         | 0.0212%, 40s   | 0.0457%, 2m24s |
| 640  | Transformer | 0.0014%, 12s   | 0.0051%, 33s   |
|      | GCN         | 0.0141%, 1m15s | 0.0324%, 4m39s |
| 1280 | Transformer | 0.0012%, 23s   | 0.0038%, 1m6s  |
|      | GCN         | 0.0107%, 2m26s | 0.0229%, 9m19s |

表8掩模建模消融研究。

| METHOD              | TSP-500        | TSP-1000      |
|---------------------|----------------|---------------|
| DIFUSCO             | 0.87%, 19.1m   | 1.31%, 51.9m  |
| Fast T2T            | 0.21%, 6.9m    | 0.42%, 18.3m  |
| MaskCO-GCN (T=320)  | 0.0212%, 40s   | 0.046%, 2m24s |
| MaskCO-GCN (T=640)  | 0.0141%, 1m15s | 0.032%, 4m39s |
| MaskCO-GCN (T=1280) | 0.0107%, 2m26s | 0.023%, 9m19s |

具有一致性(Li等, 2024)。为TSP指定了双向AR, 允许在两端扩展当前的游览段。AR和双向AR是通过在输出热图上应用自回归掩蔽方案来实现的, 确保在每一步中只能选择与部分巡回的结束节点相关的边。对于宽松的AR解码, 保持连续的漫游段的要求是宽松的;相反, 它每一步全局插入一个边缘。这可以通过简单地设置T和K等于问题大小来实现。我们还将MaskCo视为预训练模型, 并使用其中一个sota(即优化一致性模型)对其进行微调(Li等人, 2024)。由于输入要求不同, 直接评估是不可行的, 我们继承模型权值, 并使用其原始训练方法进行1 epoch微调。

实验结果。值得注意的是, 与之前的SOTA监督AR方法(如Drakulic等人(2023))相比, 用MaskCO训练的模型可以直接执行AR解码, 并取得了更好的性能;罗等人(2024), 尽管后者采用了额外的增强搜索技术, 如波束搜索。这突出了掩模学习在获取更丰富的组合优化表示方面的有效性。一致性实验表明, 1万元微调解锁了具有不同公式的解码, 验证了学习表征的通用性。

### 5.3 消融研究

修正机理的消融。如表5所示, 在TSP-500上, 我们观察到引入校正机制后, 差距缩小了20%以上。与先前的扩散求解器类似, 仅仅在单个建设性通道内增加模型推断的数量可以提供显著的增益, 但这些增益的效率是有限的。相比之下, 通过掩模和重建过程增加修正的数量更好地利用了训练目标和模型的能力, 产生了明显优越的成本效益比。

消融的建筑和面具建模。为了隔离架构效果, 我们用包含边缘特征的图卷积网络(GCN)替换了我们的变压器(Joshi等人, 2019), 除了网络深度与我们的变压器配置相匹配外, 保留了它们的设置。表7显示了变压器架构的显著改进。请注意, 与GCN相比, 变压器模型只需要TSP-500上大约1/5的训练时间。这种效率可以进行广泛的训练, 并有助于变压器的卓越性能, 使它们更适合具有挑战性的表示学习任务。更多的训练资源对比见附录F.4。为了隔离屏蔽建模的影响, 我们将具有GCN主干的MaskCO (MaskCO-GCN)与其他基于GCN的方法进行比较, 其中屏蔽建模是唯一的区别。表8表明, 与Fast T2T相比, MaskCO-GCN实现了9倍的最优性差距减少和8倍的加速, 或者, 在大约2倍的加速下实现了18倍的差距减少。这突出了掩模建模的强度。

表9:TSP-100和500上的无最优解训练( $T=2560$ )。DO表示2-opt标签上表10:无最优解的训练;Dz ( $z \geq 1$ )训练表示使用D( $z - 1$ )的伪标签进行自我训练。

在TSP-1000上,  $T=2560$  “将军”表示TSP-500的训练和TSP-1000的测试。

| METHOD          | TSP-100 |        | TSP-500 |        |
|-----------------|---------|--------|---------|--------|
|                 | OBJ.    | GAP    | OBJ.    | GAP    |
| 2Opt (128 runs) | 7.905   | 1.920% | 17.703  | 6.994% |
| MaskCO (D0)     | 7.756   | 0.001% | 16.606  | 0.362% |
| MaskCO (D1)     | 7.756   | 0.000% | 16.561  | 0.089% |
| MaskCO (D2)     | 7.756   | 0.000% | 16.556  | 0.059% |

| METHOD              | TSP-1000 |        |
|---------------------|----------|--------|
|                     | OBJ.     | GAP    |
| 2Opt (128 runs)     | 25.052   | 8.366% |
| MaskCO (Gen. as D0) | 23.288   | 0.733% |
| MaskCO (D1)         | 23.197   | 0.342% |
| MaskCO (D2)         | 23.186   | 0.295% |

## 5.4 无最优解训练范式实验

受到注入模型的蒸馏技术的启发(Luhman & Luhman, 2021;Liu等人, 2022)和SIT (罗等人, 2025), 我们提出了一个两阶段训练变体, 不需要最优解, 但超过sota。阶段1从低质量启发式标签初始化模型(2-opt, 重启128次);如果有预训练模型可用, 则可以跳过这一阶段。阶段2执行自训练:模型在伪标记未标记的实例和对这些标签进行轻量级微调之间交替, 在没有真实值优化的情况下逐步改进。这种范式将标记的最优解用于计算:阶段1是启发式标签上的标准监督学习;第二阶段是无监督的自训练, 利用模型的能力来改进自己的伪标签。

如表9所示, 仅在2-opt输出上训练的MaskCO提取了有用的信号, 并且优于它的老师。在TSP-100上, 虽然2-opt表现出1.9%的最优性差距, 但MaskCO达到了0.001%的最优性差距。这个阶段反映了主要的训练设置, 只是在数据源上有所不同。在每次迭代中, 我们对65, 536个TSP-50、4,096个TSP-500和2,048个TSP-1000实例进行伪标记, 并以大约1/60的完整运行梯度步长进行微调。只需一次迭代, MaskCO在所有尺度上都超过了Fast T2T, 如表9和表10所示。

## 6 结论

本文提出了MaskCO, 一种掩模生成范式, 它将神经组合优化的学习过程定义为解决方案级的自监督学习过程, 以实现有效和可扩展的表示学习。通过迭代掩蔽和再生的动态推理算法进一步解锁了学习到的表征, 以模拟解决问题的有效搜索过程。实验结果表明, 与现有最先进的神经解算器相比, 该算法有了显著的改进, 在解决TSP、CVRP和MIS等问题时, 最优性差距显著减少, 速度显著加快。MaskCO显示了在组合优化中为性能进步和预训练模型铺平道路的潜力。

## 伦理声明

这项工作遵循ICLR道德准则, 并一直致力于负责任的研究实践。该研究不涉及人类受试者、敏感个人数据或潜在有害应用。我们已经努力确保整个研究过程的透明度、可重复性和科学完整性, 包括准确报告方法和结果。不存在可能影响研究工作的资金来源或隶属关系方面的利益冲突。我们的目标是我们的研究对机器学习社区和整个社会做出积极贡献, 促进公平、可访问性和开放的科学探究。如果出现任何不可预见的更广泛的影响, 我们将继续致力于负责任地解决这些问题。

## 可重复性声明

我们致力于按照ICLR道德准则, 维护科学卓越和透明度的高标准。为了确保我们结果的可重复性, 我们在正文和附录中详细描述了我们的方法(第4节)、模型架构(第4.4小节)、超参数(附录E.2)、推理算法(算法1)和数据集配置(附录E.3)。代码将在接受后公开提供。

## 参考文献

- David Applegate, Ribert Bixby, Vasek Chvatal, and William Cook. Concorde tsp solver, 2006. Hangbo Bao, Li Dong, Songhao Piao, and Furu Wei. Beit: Bert pre-training of image transformers, 2022. URL <https://arxiv.org/abs/2106.08254>.
- Yoshua Bengio, Andrea Lodi, and Antoine Prouvost. Machine learning for combinatorial optimization: a methodological tour d'horizon. *European Journal of Operational Research*, 2021.
- Federico Berto, Chuanbo Hua, Nayeli Gast Zepeda, Andr Hottung, Niels Wouda, Leon Lan, Junyoung Park, Kevin Tierney, and Jinkyoo Park. Routefinder: Towards foundation models for vehicle routing problems, 2025. URL <https://arxiv.org/abs/2406.15007>.
- Jieyi Bi, Yining Ma, Jianan Zhou, Wen Song, Zhiguang Cao, Yaoxin Wu, and Jie Zhang. Learning to handle complex constraints for vehicle routing problems, 2024. URL <https://arxiv.org/abs/2410.21066>.
- Maximilian Böther, Otto Kißig, Martin Taraz, Sarel Cohen, Karen Scidel, and Tobias Friedrich. What's wrong with deep learning in tree search for combinatorial optimization. *arXiv preprint arXiv:2201.10494*, 2022.
- Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877-1901, 2020.
- Quentin Cappart, Didier Chételat, Elias Khali, Andrea Lodi, Christopher Morris, and Petar Velickovic. Combinatorial optimization and reasoning with graph neural networks. *arXiv preprint arXiv:2102.09544*, 2021.
- Huiwen Chang, Han Zhang, Lu Jiang, Ce Liu, and William T. Freeman. Maskgit: Masked generative image transformer, 2022. URL <https://arxiv.org/abs/2202.04200>.
- Xinyan Chen, Yang Li, Runzhong Wang, and Junchi Yan. Mixsatgen: Learning graph mixing for sat instance generation. In *The Twelfth International Conference on Learning Representations*, 2024. Xinyun Chen and Yuandong Tian. Learning to perform local rewriting for combinatorial optimization. *Advances in Neural Information Processing Systems*, 32, 2019.
- Paulo R d O Costa, Jason Rhuggenaath, Yingqian Zhang, and Alp Akcay. Learning 2-opt heuristics for the traveling salesman problem via deep reinforcement learning. In *Asian Conference on Machine Learning*, pp. 465-480, 2020.
- Paulo R de O da Costa, Jason Rhuggenaath, Yingqian Zhang, and Alp Akcay. Learning 2-opt heuristics for the traveling salesman problem via deep reinforcement learning. *arXiv preprint arXiv:2004.01608*, 2020.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies*, volume 1 (long and short papers), pp. 4171-4186, 2019.
- Darko Drakulic, Sofia Michel, Florian Mai, Arnaud Sors, and Jean-Marc Andreoli. Ba-nco: Bisimulation quotienting for efficient neural combinatorial optimization. *Advances in Neural Information Processing Systems*, 36:77416-77429, 2023.
- Darko Drakulic, Sofia Michel, and Jean-Marc Andreoli. Goal: A generalist combinatorial optimization agent learner, 2025. URL <https://arxiv.org/abs/2406.15079>.
- Paul Erdős, Alfréd Rényi, et al. On the evolution of random graphs. *Publ. Math. Inst. Hung. Acad. Sci*, 5(1):17-60, 1960.
- Zhang-Hua Fu, Kai-Bin Qiu, and Hongyuan Zha. Generalize a small pre-trained model to arbitrarily large tsp instances. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 35, pp. 7474-7482, 2021.

- Simon Geisler, Johanna Sommer, Jan Schuchardt, Aleksandar Bojchevski, and Stephan Günnemann. Generalization of neural combinatorial solvers through the lens of adversarial robustness. In International Conference on Learning Representations, 2022.
- Nathan Grinsztajn, Daniel Furelos-Blanco, Shikha Surana, Clément Bonnet, and Thomas D. Barret. Winner takes it all: Training performant rl populations for combinatorial optimization, 2023. URL: <https://arxiv.org/abs/2210.03475>.
- Ziao Guo, Yang Li, Chang Liu, Wenli Ouyang, and Junchi Yan. Acn-milp: Adaptive constraint modification via grouping and selection for hardness-preserving milp instance generation. In Forty-first International Conference on Machine Learning, 2024.
- Gurobi Optimization. Gurobi optimizer reference manual. <http://www.gurobi.com>, 2020.
- Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners, 2021. URL <https://arxiv.org/abs/2111.06377>.
- Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pp. 16000-16009, 2022.
- Keld Helsgaun. An extension of the lin-kernighan-helsgaun tsp solver for constrained traveling salesman and vehicle routing problems. Roskilde: Roskilde University, pp. 2-50, 2017.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. Advances in neural information processing systems, 33:6840-6851, 2020.
- André Hottung, Bhanu Bhandari, and Kevin Tierney. Learning a latent search space for routing problems using variational autoencoders. In International Conference on Learning Representations, 2021.
- André Hottung, Mridul Mahajan, and Kevin Tierney. Polynet: Learning diverse solution strategies for neural combinatorial optimization. In The Thirteenth International Conference on Learning Representations, 2025. URL <https://openreview.net/forum?id=TKuYWeFE6S>.
- Qingchun Hou, Jingwei Yang, Yiqiang Su, Xiaoging Wang, and Yuming Deng. Generalize learned heuristics to solve large-scale vehicle routing problems in real-time. In The Eleventh International Conference on Learning Representations, 2023.
- Ziwei Huang, Jianan Zhou, Zhiguang Cao, and Yixin Xu. Rethinking light decoder-based solvers for vehicle routing problems, 2025. URL <https://arxiv.org/abs/2503.00753>.
- Benjamin Hudson, Qingbiao Li, Matthew Malencia, and Amanda Prorok. Graph neural network guided local search for the traveling salesperson problem. In International Conference on Learning Representations, 2022. URL <https://openreview.net/forum?id=ar92oEosBIg>.
- Chaitanya K Joshi, Thomas Laurent, and Xavier Bresson. An efficient graph convolutional network technique for the travelling salesman problem. arXiv preprint arXiv:1906.01227, 2019.
- Nikolaos Karalias and Andreas Loukas. Erdos goes neural: an unsupervised learning framework for combinatorial optimization on graphs. Advances in Neural Information Processing Systems, 33: 6659-6672, 2020.
- Elias Khalil, Hanjun Dai, Yuyu Zhang, Bistra Dilikina, and Le Song. Learning combinatorial optimization algorithms over graphs. Advances in neural information processing systems, 30, 2017.
- Minsu Kim, Junyoung Park, and Jinkyoo Park. Sym-nco: Leveraging symmetry for neural combinatorial optimization. arXiv preprint arXiv:2205.13209, 2022.
- Wouter Kool, Herke Van Hoof, and Max Welling. Attention, learn to solve routing problems! arXiv preprint arXiv:1803.08475, 2018.

- Bernhard H Korte, Jens Vygen, B Korte, and J Vygen. Combinatorial optimization, volume 1. Springer, 2011.
- Yeong-Dae Kwon, Jinho Choo, Byoungiip Kim, Ijoo Yoon, Youngjune Gwon, and Seungjai Min. Pomo: Policy optimization with multiple optima for reinforcement learning. *Advances in Neural Information Processing Systems*, 33:2188-21198, 2020.
- Sebastian Lamm, Peter Sanders, Christian Schulz, Darren Strash, and Renato F Werneck. Finding near-optimal independent sets at scale. In *2016 Proceedings of the Eighteenth Workshop on Algorithm Engineering and Experiments (ALENEX)*, pp. 138-150. SIAM, 2016.
- Sirui Li, Zhongxia Yan, and Cathy Wu. Learning to delegate for large-scale vehicle routing. *Advances in Neural Information Processing Systems*, 34:26198-26211, 2021.
- Tianhong Li, Huiwen Chang, Shlok Kumar Mishra, Han Zhang, Dina Katabi, and Dilip Krishnan. Mage: Masked generative encoder to unify representation learning and image synthesis, 2023a. URL <https://arxiv.org/abs/2211.09117>.
- Yang Li, Xinyan Chen, Wenxuan Guo, Xijun Li, Wangian Luo, Junhua Huang, Hui-Ling Zhen, Mingxuan Yuan, and Junchi Yan. Hardsatgen: Understanding the difficulty of hard sat formula generation and a strong structure-hardness-aware baseline. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, 2023b.
- Yang Li, Jinpei Guo, Runzhong Wang, and Junchi Yan. T2t: From distribution learning in training to gradient search in testing for combinatorial optimization. In *Advances in Neural Information Processing Systems*, 2023c.
- Yang Li, Jinpei Guo, Runzhong Wang, Hongyuan Zha, and Junchi Yan. Fast t2t: Optimization consistency speeds up diffusion-based training-to-testing solving for combinatorial optimization. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024.
- Yang Li, Lvda Chen, Haonan Wang, Runzhong Wang, and Junchi Yan. Generation as search operator for test-time scaling of diffusion-based combinatorial optimization. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025a.
- Yang Li, Zhichen Dong, Yuhan Sun, Weixun Wang, Shaopan Xiong, Yijia Luo, Jiashun Liu, Han Lu, Jiamang Wang, Wenbo Su, et al. Attention illuminates llm reasoning: The preplan-and-anchor rhythm enables fine-grained policy optimization. *arXiv preprint arXiv:2510.13554*, 2025b.
- Yang Li, Jiale Ma, Wenzheng Pan, Runzhong Wang, Haoyu Geng, Nianzu Yang, and Junchi Yan. Unify ml4tsp: Drawing methodological principles for tsp and beyond from streamlined design space of learning and search. In *The Thirteenth International Conference on Learning Representations*, 2025c.
- Yang Li, Jiale Ma, Yebin Yang, Qitian Wu, Hongyuan Zha, and Junchi Yan. Generative modeling reinvents supervised learning: Label repurposing with predictive consistency learning. In *Forty-second International Conference on Machine Learning*, 2025d.
- Zhuwen Li, Qifeng Chen, and Vladlen Koltun. Combinatorial optimization with graph convolutional networks and guided tree search. *Advances in neural information processing systems*, 31, 2018.
- Qi Liu, Xinhao Zheng, Rengui Xia, Qinxiang Cao, and Junchi Yan. Bootstrapping hierarchical autoregressive formal reasoner with chain-of-proxy-autoformalization. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025.
- Qi Liu, Kangjie Bao, Yue Yang, Xinhao Zheng, Rengui Xia, Qinxiang Cao, and Junchi Yan. Let's explore step by step: Generating provable formal statements with deductive exploration. In *The Fourteenth International Conference on Learning Representations*, 2026.
- Xiao Liu, Fanjin Zhang, Zhenyu Hou, Li Mian, Zhaoyu Wang, Jing Zhang, and Jie Tang. Self-supervised learning: Generative or contrastive. *IEEE transactions on knowledge and data engineering*, 35(1):857-876, 2021.

- Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow, 2022. URL <https://arxiv.org/abs/2209.03003>.
- Rujiao Long, Yang Li, Xingyao Zhang, Weixun Wang, Tiangianjin Lin, Xi Zhao, Yuchi Xu, Wenbo Su, Junchi Yan, and Bo Zheng. Reasoning palette: Modulating reasoning via latent contextualization for controllable exploration for (v) lms. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2026.
- Eric Luhman and Troy Luhman. Knowledge distillation in variational generative modes for improved sampling speed, 2021. URL <https://arxiv.org/abs/2101.02388>.
- Fu Luo, Xi Lin, Fei Liu, Qingfu Zhang, and Zhenkun Wang. Neural combinatorial optimization with heavy decoder: Toward large scale generalization. Advances in Neural Information Processing Systems, 36, 2024.
- Fu Luo, Xi Lin, Yaoxin Wu, Zhenkun Wang, Tong Xialiang, Mingxuan Yuan, and Qingfu Zhang. Boosting neural combinatorial optimization for large-scale vehicle routing problems. In The Thirteenth International Conference on Learning Representations, 2025. URL <https://openreview.net/forum?id=TbTJJNjumY>
- Jiale Ma, Wenzheng Pan, Yang Li, and Junchi Yan. Coexpander: Adaptive solution expansion for combinatorial optimization. In Forty-second International Conference on Machine Learning, 2025a.
- Jiale Ma, Wenzheng Pan, Yang Li, and Junchi Yan. M14co-bench-101: Benchmark machine learning for classic combinatorial problems on graphs. In The Thirty-ninth Annual Conference on Neural Information Processing Systems Datasets and Benchmarks Track, 2025b.
- Yining Ma, Jingwen Li, Zhiguang Cao, Wen Song, Le Zhang, Zhenghua Chen, and Jing Tang. Learning to iteratively solve routing problems with dual-aspect collaborative transformer. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, and J. Wortman Vaughan (eds.), Advances in Neural Information Processing Systems, volume 34, pp. 11961-111. Curran Associates, Inc., 2021. URL [https://proceedings.neurips.cc/paper\\_files/paper/2021/file/5c53292c032b6cb8510041c54274e65f-Paper.pdf](https://proceedings.neurips.cc/paper_files/paper/2021/file/5c53292c032b6cb8510041c54274e65f-Paper.pdf).
- Yining Ma, Zhiguang Cao, and Yeow Meng Chee. Learning to search feasible and in-feasible regions of routing problems with flexible neural k-opt. In A. Oh, T. Nau-mann, A. Globerson, K. Saenko, M. Hardt, and S. Levine (eds.), Advances in Neural Information Processing Systems, volume 36, pp. 49555-49578. Curran Associates, Inc., 2023. URL [https://proceedings.neurips.cc/paper\\_files/paper/2023/file/9bae70d354793a95fa18751888cea07d-Paper-Conference.pdf](https://proceedings.neurips.cc/paper_files/paper/2023/file/9bae70d354793a95fa18751888cea07d-Paper-Conference.pdf).
- Yimeng Min, Yiwei Bai, and Carla P Gomes. Unsupervised learning for solving the travelling salesman problem. Advances in Neural Information Processing Systems, 36, 2024.
- Wenzheng Pan, Hao Xiong, Jiale Ma, Wentao Zhao, Yang Li, and Junchi Yan. UniCO: On unified combinatorial optimization via problem reduction to matrix-encoded general TSP. In The Thirteenth International Conference on Learning Representations, 2025. URL <https://openreview.net/forum?id=yEwakMNIex>.
- Xiaohan Qin, Xiaoxing Wang, Ning Liao, Cancheng Zhang, Xiangdong Zhang, Mingquan Feng, Jingzhi Wang, and Junchi Yan. sstoken: Self-modulated and semantic-aware token selection for llm fine-tuning. arXiv preprint arXiv:2510.18250, 2025.
- Ruizhong Qiu, Zhiqing Sun, and Yiming Yang. Dimes: A differentiable meta solver for combinatorial optimization problems. arXiv preprint arXiv:2210.04123, 2022.
- Alec Radford, Karthik Narasimhan, Tim Salimans, Ilya Sutskever, et al. Improving language understanding by generative pre-training. 2018.
- Sebastian Sanokowski, Wilhelm Berghammer, Sepp Hochreiter, and Sebastian Lehner. Variational annealing on graphs for combinatorial optimization, 2023. URL <https://arxiv.org/abs/2311.14156>.

- Sebastian Sanokowski, Sepp Hochreiter, and Sebastian Lehner. A diffusion model framework for unsupervised neural combinatorial optimization, 2024. URL <https://arxiv.org/abs/2406.01661>.
- Alberto Santini, Michael Schneider, Thibaut Vidal, and Daniele Vigo. Decomposition strategies for vehicle routing heuristics. *INFORMS Journal on Computing*, 35(3):543-559, 2023. doi: 10.1287/joc.2023.1288.
- Noam Shazeer. Glu variants improve transformer, 2020. URL <https://arxiv.org/abs/2002.05202>.
- Jingyan Sui, Shizhe Ding, Ruizhi Liu, Liming Xu, and Dongbo Bu. Learning 3-opt heuristics for traveling salesman problem via deep reinforcement learning. In *Asian Conference on Machine Learning*, pp. 1301-1316. PMLR, 2021.
- Zhiging Sun and Yiming Yang. DIFUSCO: Graph-based diffusion solvers for combinatorial optimization. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=JV8Ff01gVV>.
- A Vaswani. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.
- Thibaut Vidal, Teodor Gabriel Crainic, Michel Gendreau, Nadia Lahrichi, and Walter Rei. A hybrid genetic algorithm for multidepot and periodic vehicle routing problems. *Operations Research*, 60 (3):611-624, 2012.
- Oriol Vinyals, Meire Fortunato, and Navdeep Jaitly. Pointer networks. *Advances in neural information processing systems*, 28, 2015.
- Haoyu Peter Wang, Nan Wu, Hang Yang, Cong Hao, and Pan Li. Unsupervised learning for combinatorial optimization with principled objective relaxation. In *Advances in Neural Information Processing Systems*, 2022.
- Runzhong Wang, Ziao Guo, Shaofei Jiang, Xiaokang Yang, and Junchi Yan. Deep learning of partial graph matching via differentiable top-k. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 6272-6281, 2023.
- Shiyue Wang, Ziao Guo, Changhong Lu, and Junchi Yan. Fractional langevin dynamics for combinatorial optimization via polynomial-time escape. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025a.
- Weixun Wang, XiaoXiao Xu, Wanhe An, Fangwen Dai, Wei Gao, Yancheng He, Ju Huang, Qiang Ji, Hangi Jin, Xiaoyang Li, et al. Let it flow: Agentic crafting on rock and roll, building the rome model within an open agentic learning ecosystem. *arXiv preprint arXiv:2512.24873*, 2025b.
- Yu Wang, Yang Li, Junchi Yan, and Yi Chang. Strudico: Structured denoising diffusion with gradient-free inference-stage boosting for memory and time efficient combinatorial optimization. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.
- Huaijin Wu, Wei Liu, Yatao Bian, Jiayang Wu, Nianzu Yang, and Junchi Yan. Ebmdock: Neural probabilistic protein-protein docking via a differentiable energy model. In *The Twelfth International Conference on Learning Representations*, 2024a.
- Huanjin Wu, Xinyu Ye, and Junchi Yan. Qvae-mole: The quantum vae with spherical latent variable learning for 3-d molecule generation. *Advances in Neural Information Processing Systems*, 37: 22745-22771, 2024b.
- Yaoxin Wu, Wen Song, Zhiguang Cao, Jie Zhang, and Andrew Lim. Learning improvement heuristics for solving routing problems. *IEEE transactions on neural networks and learning systems*, 33(9): 5057-5069, 2021.
- Nianzu Yang, Huaijin Wu, Kaipeng Zeng, Yang Li, Siyuan Bao, and Junchi Yan. Molecule generation for drug design: a graph learning perspective. *Fundamental Research*, 2024.

- Haoran Ye, Jiarui Wang, Helan Liang, Zhiguang Cao, Yong Li, and Fanzhang Li. Glop: Learning global partition and local construction for solving large-scale routing problems in real-time. In Proceedings of the AA Conference on Artificial Intelligence, volume 38, pp. 2024-202, 2024.
- Dinghuai Zhang, Hanjun Dai, Nikolay Malkin, Aaron Courville, Yoshua Bengio, and Ling Pan. Let the flows tell: Solving graph combinatorial optimization problems with gflownets. arXiv preprint arXiv:2305.17010, 2023.
- Xinhao Zheng, Yang Li, Cunxin Fan, Huajin Wu, Xinhao Song, and Junchi Yan. Learning plaintext-ciphertext cryptographic problems via anf-based sat instance representation. Advances in Neural Information Processing Systems, 2024.
- Zhi Zheng, Changliang Zhou, Tong Xialiang, Mingxuan Yuan, and Zhenkun Wang. Udc: A unified neural divide-and-conquer framework for large-scale combinatorial optimization problems, 2025. URL <https://arxiv.org/abs/2407.00312>.
- Changliang Zhou, Xi Lin, Zhenkun Wang, Xialiang Tong, Mingxuan Yuan, and Qingfu Zhang. Instance-conditioned adaptation for large-scale generalization of neural combinatorial optimization, 2024a. URL <https://arxiv.org/abs/2405.01906>.
- Jianan Zhou, Zhiguang Cao, Yaoxin Wu, Wen Song, Yining Ma, Jie Zhang, and Chi Xu. Mvmoe: Multi-task vehicle routing solver with mixture-of-experts, 2024b. URL <https://arxiv.org/abs/2405.01029>.
- Zefang Zong, Xiaochen Wei, Guozhen Zhang, Chen Gao, Huandong Wang, and Yong Li. Solving diverse combinatorial optimization problems with a unified model, 2025. URL <https://openreview.net/forum?id-Kc3yolL5oR>.

## 附录

### 大型语言模型的使用(大型语言模型)

我们严格地使用大型语言模型作为文字编辑助手，以提高稿件的清晰度、可读性和风格。这些模型被用于诸如改写句子、检查语法、协调术语和平滑散文流等任务。它们不会产生技术内容、分析、结果或结论，也不会修改我们主张的实质内容。所有al辅助编辑都经过作者的审查和批准，没有向模型提供任何机密数据。

## B对某些设计选择的讨论

### B.1 关于缺席一个特别的。MASK令牌

在标准掩码生成建模中(Devlin et al, 2019; Li等人, 2023a; Chang et al., 2022), 在词汇表 $v$ 中引入了一个特殊的标记[MASK], 我们将扩展的词汇表定义为 $V_{\text{mask}} = V \cup \{\text{[MASK]}\}$ 。可训练的嵌入与扩展词汇表中的每个标记相关联, 包括(MASK), 以在有限的嵌入维度内表示更大的有效词汇表(例如, 使用 $k$ 维嵌入建模100k个标记词汇表)。

然而, 在组合优化(CO)中, 我们主要处理 $V = \{0, 1\}$ 的二元决策变量。将 $d$ 维嵌入分配给这些变量通常是计算冗余的。这是因为二进制变量已经是实值的, 并且对应于最小词汇量( $|V| = 2$ )。例如, 在具有 $n$ 个节点且嵌入维数为 $d$ 的车辆路径问题(vrp)中, 大约有 $n^2/2$ 个二进制变量。引入[MASK]令牌将打破这种标量效率, 需要更高维度的嵌入空间来区分掩码和二进制状态。为了保持架构的简单性和计算效率, 我们放弃了[MASK]令牌, 而是选择了一个通过选择的角度来处理掩码位置的公式。

### B.2 选择vs.决策公式

简而言之, 决策问题涉及分配 $N$ 个二进制变量, 以便在某些约束下最小化目标函数。虽然它在理论上等同于选择问题公式, 但我们发现使用选择公式提供了几个实际优势:

- 消除掩码令牌: 通过将任务框架为选择下一个组件添加到部分解决方案中, 我们自然地回避了对显式IMASK令牌的需求, 继承了第B.1节中讨论的效率。
- 直观建模: 选择范式为许多CO问题提供了一种更自然的建模方式。例如, 在VRPS问题中, 解决方案自然地表示为选择边来形成路由, 而在MIS问题中, 目标是选择一组节点。此外, 许多现有的将热图解码为解的方法, 本质上是解决了一个选择问题。这种方法, 在之前的作品中通常被称为贪心插入(Sun & Yang, 2023; Li et al., 2023; 2024), 与本文采用的选择函数公式直接对应。

### B.3 选择函数

在这项工作中, 我们采用了贪婪选择函数, 其中模型迭代地提交具有最高预测置信度的变量。我们选择这种直截了当的策略来隔离和展示MaskCO固有的表征能力, 而不是依赖于复杂的选择函数。尽管如此, 选择函数仍然是一个模块化的组件。在更复杂的场景中, 可以通过最大化新选择变量的平均分来取代它, 这可以使用动态规划或有界宽度树sach来实现。

#### B.4 完整解执行的备选策略

回想一下，对于具有aibl解心性的问题，在逐步解码中， $i(x_k)(c)$ 我们应用了一个完成步骤：

$$\hat{x} \leftarrow f_G(\hat{x}^{(K)}, p_\theta(G, \hat{x}^{(K-1)}), |U(G)|), \quad (8)$$

重用之前的分数以避免重新计算并保持一致性。此策略选择尽可能多的元素，使其特别适用于需要大量解决方案基数的问题，例如MIS。另一种方法是只选择形成有效解所需的最小数量的元素。这可以通过迭代应用来实现

$$\hat{x} \leftarrow f_G(\hat{x}, p_\theta(G, \hat{x}^{(K-1)}), |\text{supp}(\hat{x})| + 1), \quad (9)$$

直到 $x$ 成为一个完整的解。

#### C与自回归建模的比较

**MaskCO的基本解码可以看作是VRPS自回归建模的两步扩展：**

1. 为当前节点选择一条边→为任意节点选择一条边。传统上，自回归建模是基于局部边缘置信度为当前节点(即部分路由的结束节点)选择一条边，而我们扩展了这种方法，允许在全局边缘置信度的指导下为任何节点选择一条边。非顺序选择策略的灵活性确保了全局自信的边缘不会仅仅因为它们与先前选择的边缘冲突而被忽略，这些边缘可能是由于高局部置信度而较低全局相关性而被选择的。因此，这种扩展降低了由于早期的、局部有利的选择可能阻碍全局最优解而导致的次优决策的风险。仅使用此扩展对应于 $K$ 设置等于节点数的MaskCO。

2. 单步预测-多步预测。传统的自回归建模从单个预测中选择一条边，而我们将其扩展到从一个预测中选择多条边，其中边的数量与训练解耦，可以在推理阶段进行调整。这种扩展提供了速度-质量权衡的灵活性，并且通常会带来更好的可扩展性。仅使用此扩展类似于NLP中的多标记预测。

在训练过程中，MaskCO采样的部分解明显比传统的自回归方法丰富。传统的自回归方法只在解的连续部分上训练，而MaskCO在最优解的任意子集上训练，而不考虑顺序或连续性。这使模型暴露于更多样化的问题实例集和部分解结构，鼓励对潜在组合问题的更深入理解。因此，该模型学习了更鲁棒的和可泛化的表示(特别是在训练数据有限的情况下)，即使在推理时使用标准的自回归解码，也可以提高性能。

对于像MIS这样的节点选择问题，标准的自回归模型已经执行了全局节点选择。在这种情况下，对于推理，MaskCO主要引入了第二次扩展(即多步预测)，它在不改变全局选择机制的情况下提高了效率和解的精细化。在训练方面，传统的自回归方法要求模型依次预测节点，一次一个。然而，由于节点选择问题的解决方案通常是无序的，因此这种顺序建模强加了一种人为的排序，导致训练信号不明确。相比之下，MaskCO训练模型以基于集合的方式预测完整的解决方案，提供更一致和明确的训练信号，更好地与问题的非顺序性质保持一致。

#### D模型架构细节

该模型采用基于transformer的架构，利用了预归一化(Pre-norm)和SwiGLU (Shazeer, 2020) 激活函数。

设 $d_{\text{model}}$ 表示嵌入维数,  $h$ 表示注意头数,  $d_{\text{head}} = d_{\text{model}}/h$ 表示头维数,  $L$ 表示序列长度。给定层的输入 $X \in \mathbb{R}^{L \times d_{\text{model}}}$ 和邻接矩阵 $A \in \{0,1\}^{L \times L}$ , 层的输出 $Y$ 通过以下子层计算, 遵循预范数结构。

### D.1 多头自注意力机制(mhSA)

以邻接矩阵 $A$ 为偏置项的核心注意机制定义为:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}, \mathbf{A}) = \text{Softmax}(\mathbf{Q}\mathbf{K}^\top + \mathbf{A})\mathbf{V} \quad (10)$$

多头自注意力机制函数 $\text{MultiHeadsSelfAttention}(X, A)$ 将注意力头部连接起来, 然后是输出投影 $W_o$

$$\text{MultiHeadSelfAttention}(\mathbf{X}, \mathbf{A}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)\mathbf{W}^O, \quad (11)$$

其中每个头头, 计算为:

$$\text{head}_i = \text{Attention}(\mathbf{X}\mathbf{W}_i^Q, \mathbf{X}\mathbf{W}_i^K, \mathbf{X}\mathbf{W}_i^V, \mathbf{A}). \quad (12)$$

权重矩阵的维数分别为 $W$ 、 $W$ 、 $WY$ , 对于头部 $i$ 中的 $u_{\text{query}}$ 、Key和Value的保护, 权重矩阵的维数分别为 $W$ 、 $W$ 、 $WY$ , 输出投影为 $W_o$ 。

### D.2 层前向传递

该层通过MHSA子层和前馈网络(FFN)子层依次更新 $X$ , 两者都使用剩余连接:

#### D.2.1 自关注子层

该层在注意操作之前进行归一化(预范数), 并应用剩余连接:

$$\mathbf{X} \leftarrow \mathbf{X} + \text{MultiHeadSelfAttention}(\text{Norm}(\mathbf{X}), \mathbf{A}) \quad (13)$$

#### D.2.2 带有swiglu的前馈子层

该层再次执行预范数, 应用SwiGLU FFN, 并添加一个剩余连接:

$$\mathbf{X} \leftarrow \mathbf{X} + \text{SwiGLU}(\text{Norm}(\mathbf{X})) \quad (14)$$

最终的 $X$ 是Transformer层的输出 $Y$ 。

### D.3 输入和输出层

输入层。对于vrp, 原始节点特征通过可学习的线性层投射到模型嵌入空间中。对于MIS, 节点特征从标准正态分布中采样, 并线性投影到编码器嵌入空间中。

输出层(Output Layer)。对于vrp, 表示转换嵌入 $x$ 的两个不同节点 $i$ 和 $j$ 之间的连接的logit; 和 $x$ 通过内积( $x, x$ )计算, 对于MIS, 选择节点 $i$ 的logit是通过投影其嵌入 $x$ 产生的; 到单维。

## E 实验细节

### E.1 Hardware和baseline设置

所有实验均在配备NVIDIA A100 GPU和32核Intel Xeon Platinum 8352S CPU的计算平台上进行。传统的sover基线(Concorde、LKH-3、HGS、KaMIS)在单线程模式下进行评估, 遵循Ma et al. (2023); Sun & Yang (2023); 周等人(2024a)。对于没有指定超参数的基线, 我们使用他们原始论文中产生最佳解决方案质量的配置。关于CVRP-1000上的SIT (Luo et al, 2025), 由于公开发表的检查点没有在容量设置 $C = 50$ 下进行训练, 因此对我们的测试集进行直接评估是不可行的。为了确保公平的比较, 我们在 $C = 50$ 的CVRP-1000上从头开始重新训练他们的模型, 这在单个A100 GPU上需要大约10.7天。

表11:神经网络配置。

|                     | TSP | CVRP | MIS-RB-[200-300] | MIS-ER-[700-800] |
|---------------------|-----|------|------------------|------------------|
| embedding dimension | 256 | 512  | 256              | 256              |
| head dimension      | 32  | 64   | 64               | 64               |
| encoder layers      | 16  | 16   | 0                | 0                |
| decoder layers      | 6   | 6    | 12               | 24               |

## E.2 hyperparameters

### E.2.1神经网络

神经网络的超参数详见表11。编码器是指只处理问题实例(即生成条件)的组件，而解码器则额外处理部分解。

### E.2.2 推理配置

表12、13和14分别为TSP、CVRP和MIS指定了推理超参数。

关于 $p$ 和 $K$ 这两个关键超参数，它们各自在指导推理过程中发挥着不同的作用。参数 $p$ 明确地控制了开发和探索之间的权衡:如果 $p$ 太大，重构解仍然过于接近原始解，可能导致校正过程停滞;如果 $p$ 太小，重构可能会退回到从零开始生成解。同时， $K$ 控制着前向传递的分布方式，有利于每次迭代更多的采样步骤或更少步骤的更多迭代。对于更简单的任务，较小的 $K$ 值是可取的，可以促进更多的迭代细化。相比之下，对于预测具有较高不确定性(可以通过将预测归一化为概率后的熵来衡量)的较困难任务，较大的 $K$ 值有利于收集更多信息丰富的样本。

除了语义解释之外，还有几个实际因素影响超参数的选择。例如，有噪声的数据增加了预测的不确定性，因此有利于更大的 $k$ 。我们通过比较在干净(最优)数据上训练的模型与高度噪声数据(使用128次2-opt运行生成)的最优超参数来验证这一现象，如表18所示。结果表明，噪声将 $K$ 的最优值从1移动到8。对于大规模CVRP，由于数据生成的时间限制非常严格(CVRP-500每实例4分钟，CVRP-1000每实例8分钟)，也可能出现这种现象，导致训练数据有噪声。此外，跨不同 $p$ 值的不平衡学习可能会发生，即，即使在训练期间对 $p$ 进行均匀采样，模型在中等范围的 $p$ 值上通常表现较差，因为这些值对应于更具挑战性的重建场景，并且在有效学习中可能代表性不足。这些复合因素使得识别最优超参数变得非常重要，即使它们的作用被很好地理解了。

幸运的是，在我们的例子中，MaskCO的极快的评估时间使得通过网格搜索进行高效的超参数调优成为可能。例如，TSP-500的完整超参数选择只需要3.6分钟。额外的细节和实证分析可以在附录F.3中找到。在未来的作品中， $p$ 可能不会固定为常数;相反，它可以从分布中采样，定期设置，甚至由辅助神经网络动态控制。

表12:TSP的推理配置。

|                    | TSP-100 | TSP-500 | TSP-1000 |
|--------------------|---------|---------|----------|
| Sampling Steps $K$ | 1       | 1       | 2        |
| Keeping Rate $p$   | 0.2     | 0.2     | 0.1      |

表13:CVRP的推理配置。

|                    | CVRP-100 | CVRP-500 | CVRP-1000 |
|--------------------|----------|----------|-----------|
| Sampling Steps $K$ | 2        | 16       | 128       |
| Keeping Rate $p$   | 0.3      | 0.3      | 0.6       |

表14:MIS的推理配置。

|                    | RB-[200-300] | ER-[700-800] |
|--------------------|--------------|--------------|
| Sampling Steps $K$ | 1            | 1            |
| Keeping Rate $p$   | 0.6          | 0.5          |

表15:TSP的数据集配置。

|                         | TSP-100                           | TSP-500                | TSP-1000 |
|-------------------------|-----------------------------------|------------------------|----------|
| Training Dataset Size   | 1,280K                            |                        | 128K     |
| Training Dataset Solver | Concorde (Applegate et al., 2006) | LKH-3 (Helsgaun, 2017) |          |
| Test Dataset Size       | 1,280                             |                        | 128      |
| Test Dataset Solver     | Concorde (Applegate et al., 2006) |                        |          |

表16:CVRP的数据集配置。

|                         | CVRP-100                 | CVRP-500                                      | CVRP-1000 |
|-------------------------|--------------------------|-----------------------------------------------|-----------|
| Training Dataset Size   | 1,536K                   | 200K                                          | 100K      |
| Training Dataset Solver | HGS (Vidal et al., 2012) | HGS with Decomposition (Santini et al., 2023) |           |
| Test Dataset Size       | 1,280                    | 128                                           | 64        |
| Test Dataset Solver     |                          | HGS (Vidal et al., 2012)                      |           |

表17:MIS的数据集配置。

|                         | RB-[200-300]              | ER-[700-800] |
|-------------------------|---------------------------|--------------|
| Training Dataset Size   | 90,000                    | 163,840      |
| Training Dataset Solver | KaMIS (Lamm et al., 2016) |              |
| Test Dataset Size       | 500                       | 128          |
| Test Dataset Solver     | KaMIS (Lamm et al., 2016) |              |

### E.3 datasets

TSP、CVRP和MIS的数据集配置分别总结于表15、表16和表17。

表18:在干净(最优)数据上训练的模型与由128次运行的2-opt生成的高噪声数据的最优超参数比较。对于在干净数据上训练的模型,最优配置是 $(K, p) = (1, 0.2)$ , 而对于噪声数据,它是 $(K, p) = (8, 0.2)$ 。此外,对于固定的 $K$ ,最优 $p$ 根据数据质量而变化,这表明预测不确定性在多个维度上影响超参数选择。

| TSP-500 |     |                |                |
|---------|-----|----------------|----------------|
| $K$     | $p$ | CLEAN DATA     | NOISY DATA     |
| 1       | 0.1 | 0.0041%        | 1.9819%        |
|         | 0.2 | <b>0.0020%</b> | 1.2726%        |
|         | 0.3 | 0.0051%        | 0.9309%        |
|         | 0.4 | 0.0073%        | 0.8800%        |
|         | 0.5 | 0.0115%        | 0.9427%        |
|         | 0.6 | 0.0179%        | 1.2118%        |
|         | 0.7 | 0.0257%        | 1.5670%        |
|         | 0.8 | 0.0443%        | 1.9170%        |
|         | 0.9 | 0.0917%        | 2.1689%        |
| 8       | 0.1 | 0.0048%        | 0.6528%        |
|         | 0.2 | 0.0070%        | <b>0.6371%</b> |
|         | 0.3 | 0.0075%        | 0.6710%        |
|         | 0.4 | 0.0093%        | 0.7144%        |
|         | 0.5 | 0.0095%        | 0.7767%        |
|         | 0.6 | 0.0107%        | 0.8466%        |
|         | 0.7 | 0.0111%        | 0.8978%        |
|         | 0.8 | 0.0112%        | 0.9291%        |
|         | 0.9 | 0.0113%        | 0.9393%        |

## F 补充实验

### F.1 对求解VRPS的2-opt和宽松空间的影响

对于CVRP,我们遵循了HGS和LKH-3等先进的传统求解器的做法,放宽了容量限制以实现更大的搜索空间,并将其作为惩罚项纳入成本函数中。表19显示了2-opt启发式(带有惩罚项)在求解vrp时的有效性,特别是对于容量松弛下的CVRP,它对有效的约束处理有重要贡献。在实践中,-pt在非查询中的完全收敛在每个tertion中。我们发现 $n/100$ 步和 $n/25$ 步分别对SP和CVRP来说是足够的,其中 $n$ 表示节点数。

通过采用容量放松空间,我们观察到性能的提高。表20的结果表明,放松带来了持续的改善。实际上,HGS和LKH-3等先进的传统求解器在一个宽松的搜索空间内运行,NeuOpt已经证明,探索不可行的解决方案可以为基于学习的搜索方法带来好处。我们认为在测试时引入2-opt是一种相对简单的使用放松空间的方法,或者在训练时应该包括一些像NeuOpt中使用的机制。

我们还保留了直接强制执行实验设置所需的严格可靠的解决方案空间的灵活性。在表21中,我们给出了MaskCO在这种严格可行设置下的性能结果,其中选择函数单独用于处理约束。

### F.2 泛化研究

#### F.2.1 TSP

TSPLIB结果已在4.跨尺度生成结果如表22所示。

表19:采用2-opt启发式方法求解TSP和CVRP的影响。“- 2opt”表示在校正步骤之间禁用2-opt。“+ PostProcess.”表示2-opt作为最终修正后的后处理步骤应用。

| METHOD          | TSP-100 |         | TSP-500 |         | TSP-1000 |         |
|-----------------|---------|---------|---------|---------|----------|---------|
|                 | OBJ.    | GAP     | OBJ.    | GAP     | OBJ.     | GAP     |
| MaskCO (T=320)  | 7.756   | 0.0000% | 16.546  | 0.0020% | 23.120   | 0.0071% |
| - 2Opt          | 7.756   | 0.0000% | 16.546  | 0.0029% | 23.121   | 0.0110% |
| + PostProcess.  | 7.756   | 0.0000% | 16.546  | 0.0029% | 23.120   | 0.0100% |
| MaskCO (T=640)  | 7.756   | 0.0000% | 16.546  | 0.0014% | 23.119   | 0.0051% |
| - 2Opt          | 7.756   | 0.0000% | 16.546  | 0.0017% | 23.120   | 0.0079% |
| + PostProcess.  | 7.756   | 0.0000% | 16.546  | 0.0017% | 23.120   | 0.0075% |
| MaskCO (T=1280) | 7.756   | 0.0000% | 16.546  | 0.0012% | 23.119   | 0.0038% |
| - 2Opt          | 7.756   | 0.0000% | 16.546  | 0.0013% | 23.119   | 0.0054% |
| + PostProcess.  | 7.756   | 0.0000% | 16.546  | 0.0013% | 23.119   | 0.0054% |
| MaskCO (T=2560) | 7.756   | 0.0000% | 16.546  | 0.0007% | 23.119   | 0.0027% |
| - 2Opt          | 7.756   | 0.0000% | 16.546  | 0.0008% | 23.119   | 0.0044% |
| + PostProcess.  | 7.756   | 0.0000% | 16.546  | 0.0008% | 23.119   | 0.0044% |

| METHOD           | CVRP-100 |        | CVRP-500 |        | CVRP-1000 |        |
|------------------|----------|--------|----------|--------|-----------|--------|
|                  | OBJ.     | GAP    | OBJ.     | GAP    | OBJ.      | GAP    |
| MaskCO (T=640)   | 15.586   | 0.232% | 62.66    | 0.813% | 122.03    | 0.798% |
| - 2Opt           | 15.675   | 0.808% | Inf      | Inf%   | Inf       | Inf%   |
| + PostProcess.   | 15.610   | 0.384% | 62.698   | 0.882% | 122.16    | 0.898% |
| MaskCO (T=1280)  | 15.577   | 0.176% | 62.59    | 0.714% | 121.85    | 0.644% |
| - 2Opt           | 15.630   | 0.514% | Inf      | Inf%   | Inf       | Inf%   |
| + PostProcess.   | 15.601   | 0.329% | 62.664   | 0.826% | 121.98    | 0.750% |
| MaskCO (T=2560)  | 15.571   | 0.135% | 62.53    | 0.608% | 121.69    | 0.514% |
| - 2Opt           | 15.606   | 0.360% | Inf      | Inf%   | Inf       | Inf%   |
| + PostProcess.   | 15.593   | 0.277% | 62.642   | 0.791% | 121.81    | 0.615% |
| MaskCO (T=5120)  | 15.567   | 0.111% | 62.47    | 0.514% | 121.63    | 0.460% |
| - 2Opt           | 15.592   | 0.270% | Inf      | Inf%   | Inf       | Inf%   |
| + PostProcess.   | 15.584   | 0.223% | 62.621   | 0.758% | 121.69    | 0.516% |
| MaskCO (T=10240) | 15.563   | 0.086% | 62.43    | 0.448% | 121.60    | 0.438% |
| - 2Opt           | 15.582   | 0.205% | Inf      | Inf%   | Inf       | Inf%   |
| + PostProcess.   | 15.579   | 0.186% | 62.620   | 0.756% | 121.72    | 0.537% |

表20:容量放宽对CVRP的影响。“- Relaxation”表示容量松弛功能被禁用。

| METHOD           | CVRP-100 |        | CVRP-500 |        | CVRP-1000 |        |
|------------------|----------|--------|----------|--------|-----------|--------|
|                  | OBJ.     | GAP    | OBJ.     | GAP    | OBJ.      | GAP    |
| MaskCO (T=640)   | 15.586   | 0.232% | 62.66    | 0.813% | 122.03    | 0.798% |
| - Relaxation     | 15.661   | 0.717% | 64.60    | 3.944% | 126.36    | 4.370% |
| MaskCO (T=1280)  | 15.577   | 0.176% | 62.59    | 0.714% | 121.85    | 0.644% |
| - Relaxation     | 15.630   | 0.515% | 64.22    | 3.327% | 125.61    | 3.752% |
| MaskCO (T=2560)  | 15.571   | 0.135% | 62.53    | 0.608% | 121.69    | 0.514% |
| - Relaxation     | 15.608   | 0.374% | 63.87    | 2.768% | 124.82    | 3.095% |
| MaskCO (T=5120)  | 15.567   | 0.111% | 62.47    | 0.514% | 121.63    | 0.460% |
| - Relaxation     | 15.593   | 0.276% | 63.60    | 2.326% | 124.17    | 2.559% |
| MaskCO (T=10240) | 15.563   | 0.086% | 62.43    | 0.448% | 121.60    | 0.438% |
| - Relaxation     | 15.583   | 0.212% | 63.32    | 1.885% | 123.91    | 2.347% |

表21:单独使用选择函数处理CVRP约束的结果。2-opt和容量松弛功能被禁用。

| METHOD           | CVRP-100 |        | CVRP-500 |        | CVRP-1000 |        |
|------------------|----------|--------|----------|--------|-----------|--------|
|                  | OBJ.     | GAP    | OBJ.     | GAP    | OBJ.      | GAP    |
| MaskCO (T=640)   | 15.661   | 0.717% | 64.60    | 3.944% | 126.36    | 4.370% |
| MaskCO (T=1280)  | 15.630   | 0.515% | 64.22    | 3.327% | 125.61    | 3.752% |
| MaskCO (T=2560)  | 15.608   | 0.374% | 63.87    | 2.768% | 124.82    | 3.095% |
| MaskCO (T=5120)  | 15.593   | 0.276% | 63.60    | 2.326% | 124.17    | 2.559% |
| MaskCO (T=10240) | 15.583   | 0.212% | 63.32    | 1.885% | 123.91    | 2.347% |

表22 TSP的跨尺度概化结果。

| Testing \ Training |                               | TSP-100               | TSP-500                | TSP-1000               |
|--------------------|-------------------------------|-----------------------|------------------------|------------------------|
| TSP100             | Fast T2T ( $T_s=20, T_g=20$ ) | 7.76, 0.01%           | <b>7.77, 0.23%</b>     | 7.78, 0.34%            |
|                    | MaskCO (T=2560)               | <b>7.756, 0.0000%</b> | 7.796, 0.521%          | 7.790, 0.437%          |
|                    | MaskCO (T=10240)              | <b>7.756, 0.0000%</b> | <b>7.773, 0.227%</b>   | <b>7.770, 0.179%</b>   |
| TSP500             | Fast T2T ( $T_s=20, T_g=20$ ) | 16.97, 2.54%          | 16.58, 0.20%           | 16.60, 0.33%           |
|                    | MaskCO (T=2560)               | 16.957, 2.485%        | <b>16.546, 0.0007%</b> | 16.546, 0.0005%        |
|                    | MaskCO (T=10240)              | <b>16.903, 2.156%</b> | <b>16.546, 0.0007%</b> | <b>16.546, 0.0001%</b> |
| TSP1K              | Fast T2T ( $T_s=20, T_g=20$ ) | <b>24.01, 3.87%</b>   | 23.25, 0.58%           | 23.20, 0.36%           |
|                    | MaskCO (T=2560)               | 24.206, 4.707%        | 23.134, 0.0702%        | 23.119, 0.0027%        |
|                    | MaskCO (T=10240)              | 24.136, 4.404%        | <b>23.129, 0.0456%</b> | <b>23.118, 0.0012%</b> |

表23:VRPLIB概化结果(T=40960)。

|               | ICAM  | NeuOpt | MaskCO       |
|---------------|-------|--------|--------------|
| VRPLIB50-200  | 4.41% | 2.62%  | <b>2.15%</b> |
| VRPLIB201-500 | 3.92% | —      | <b>3.87%</b> |

表24:MIS的概化结果。(T=32k)

| Testing \ Training |  | RB-[200-300]  | ER-[700-800] |
|--------------------|--|---------------|--------------|
| RB-[200-300]       |  | 20.08, 0.10%  | 19.96, 0.72% |
| ER-[700-800]       |  | 38.57, 14.04% | 44.59, 0.62% |

### F.2.2 CVRP

表23总结了VRPLIB基准测试的结果。ICAM (Zhou et al., 2024a)提出的混合尺度和混合容量训练策略可以进一步纳入我们的方法中, 以提高其泛化性能。

### F.2.3 MIS

模型在RB-[200-300]上进行训练, 在ER-[700-800]上进行评估, 反之亦然, 如表24所示。

### F.3 超参数研究

对于推理超参数，我们对采样步数 $K$ 和保持率 $p$ 进行网格搜索，同时保持前向传递的总数固定。结果如图3、4、5、6、7、8、9、10所示。




图3:TSP-100上采样步长 $K$ 和保持率 $p$ 的网格搜索结果。(t=320)




图4:TSP-500上采样步长 $K$ 和保持率 $p$ 的网格搜索结果。(t=320)

### F.4 训练资源比较

除CVRP-500和CVRP-1000上训练的模型为768次，TSP-1000上训练的模型为300次外，所有模型的默认训练时间为600次。我们在表25中直接比较了TSP与T2T和快速T2T的训练时间(Li et al., 2024)。值得注意的是，MaskCO所需的训练时间不到TSP-1000上快速T2T所需时间的1/13。T2T和快速T2T训练一个12层GCN(50个epoch)，而我们训练一个22层变压器。这种比较也反映了GCN的计算成本比变压器昂贵得多。




图5:TSP-1000上采样步长K和保持率p的网格搜索结果。(t=320)




图6:CVRP-100上采样步长K和保持率p的网格搜索结果。(t=640)

表25:使用单个A100 GPU的TSP训练资源使用情况比较。

|          | TSP-100      | TSP-500      | TSP-1000     |
|----------|--------------|--------------|--------------|
| T2T      | 8.6Day       | 2.7Day       | 5.1Day       |
| Fast T2T | 20.3Day      | 5.9Day       | 13.5Day      |
| MaskCO   | $\leq 2$ Day | $\leq 1$ Day | $\leq 1$ Day |

#### F.5 训练时间为自我培训方案

对于TSP-100和TSP-500，自我培训方案大约需要标准训练时间的1/2。最初的训练使用与标准训练相同的设置，但只收敛了150次，




图7:CVRP-500上采样步长K和保持率p的网格搜索结果。(t=2560)




图8:CVRP-1000上采样步长K和保持率p的网格搜索结果。(t=5120)

只有标准方法所需的600个epoch的四分之一左右。另外1/4的时间用于标记(即用该模式解决未标记的实例), 而每个微调步骤花费的时间不到10分钟, 因为覆盖在15个epoch内发生。对于TSP-1000, 不需要初始训练, 将总时间减少到标准培训成本的约1/4。

## F.6 TSPTW实验

MaskCO对更复杂的问题具有适应性。为了验证MaskCO对更复杂问题的适应性, 我们对带时间窗的旅行推销员问题(TSPTW)进行了实验。我们在TSPTW-50上进行了实验, 评估了中等和硬级别变体的性能, 如下(Bi等人, 2024)。除了(Bi等人, 2024)中报告的指标外, 我们还包括约束违反(不可行的解决方案的平均值)。测试集取自(Bi等人, 2024)。MaskCO的所有结果都是在三个不同的种子上平均的。注意, MaskCO采用惩罚因子 $c = 200$ 的2-opt。如表26和27所示, 与专门为复杂约束处理设计的SOTA神经基线相比, MaskCO实现了




图9在MIS-RB-[200-3001]上采样步长K和保持率p的网格搜索结果。(T=-1k)




图10:在MIS-ER-[700-8001]上采样步长K和保持率p的网格搜索结果。(T=-1k)

表26:TSPTW-50 (Medium)的结果。

| METHOD                        | TSPTW-50 (Medium) |        |         |           |       |
|-------------------------------|-------------------|--------|---------|-----------|-------|
|                               | INFEASIBLE INST.  | OBJ.   | GAP     | VIOLATION | TIME  |
| LKH-3* (Helsgaun, 2017)       | 0.00%             | 13.02  | 0.00%   | —         | 7h    |
| 2Opt                          | 85.38%            | 14.830 | 13.973% | 12.393    | —     |
| AM+PIP* (Bi et al., 2024)     | 0.35%             | 13.68  | 5.06%   | —         | 11m   |
| AM+PIP-D* (Bi et al., 2024)   | 0.33%             | 13.65  | 4.87%   | —         | 11m   |
| POMO+PIP* (Bi et al., 2024)   | 0.90%             | 13.40  | 2.91%   | —         | 15s   |
| POMO+PIP-D* (Bi et al., 2024) | 0.65%             | 13.45  | 3.32%   | —         | 15s   |
| MaskCO (T=320)                | 0.040%            | 12.918 | -0.779% | 3.24e-4   | 56s   |
| MaskCO (T=640)                | 0.030%            | 12.872 | -1.131% | 3.26e-4   | 1m46s |
| MaskCO (T=1280)               | 0.027%            | 12.834 | -1.425% | 2.50e-4   | 3m26s |

可将不可行性比率降低10倍，并且在可行解决方案的溶液质量方面优于LKH-3，如负差距所示。

表27:TSPTW-50 (Hard)测试结果。

| METHOD                        | TSPTW-50 (Hard)  |        |         |           |       |
|-------------------------------|------------------|--------|---------|-----------|-------|
|                               | INFEASIBLE INST. | OBJ.   | GAP     | VIOLATION | TIME  |
| LKH-3* (Helsgaun, 2017)       | 0.12%            | 25.61  | 0.00%   | —         | 7h    |
| 2Opt                          | 100.00%          | —      | —       | 74.748    | —     |
| AM+PIP* (Bi et al., 2024)     | 1.98%            | 25.71  | 0.38%   | —         | 11m   |
| AM+PIP-D* (Bi et al., 2024)   | 4.40%            | 25.80  | 0.67%   | —         | 11m   |
| POMO+PIP* (Bi et al., 2024)   | 2.67%            | 25.66  | 0.18%   | —         | 15s   |
| POMO+PIP-D* (Bi et al., 2024) | 3.07%            | 25.69  | 0.28%   | —         | 15s   |
| MaskCO (T=320)                | 1.353%           | 25.495 | -0.459% | 0.389     | 46s   |
| MaskCO (T=640)                | 1.307%           | 25.476 | -0.534% | 0.403     | 1m24s |
| MaskCO (T=1280)               | 1.280%           | 25.448 | -0.640% | 0.411     | 2m41s |

多步解码的F7可视化

图11展示了MaskCO在TSP-500实例上的多步解码过程。该模型展示了跨不同阶段进行局部或全局决策的紧急能力。具体来说，最初的两个步骤主要用于局部决策，而随后的两个步骤过渡到执行由先前制定的结构通知的全局决策。




图11:TP-500上的多步解码可视化。(k <4)